

Decision

caltamiranda

April 2025

1 Teoría de decisión estadística

La estimación de procesos aleatorios se fundamenta en la teoría de la decisión estadística, en tanto que la información extraída del proceso aleatorio se utiliza para alcanzar un objetivo de análisis, cuyo resultado es una decisión.

Aunque la variedad de tareas que requieren la toma de decisiones es amplia, existe una formulación matemática que posee las siguientes propiedades:

- (a) Cualquier solución está orientada a la obtención de un objetivo concreto, el cual puede estar definido por una cantidad, finita o infinita, de variantes, cada una con sus respectivas ventajas y restricciones, sobre las cuales se estima la calidad de la decisión a tomar.
- (b) La decisión se toma basándose tanto en la información como en la evidencia estadística a priori, así como en los datos obtenidos durante el proceso de solución.
- (c) La toma de decisión dentro de un conjunto de posibles variantes puede contemplar la incertidumbre, determinada por la probabilidad asociada a la elección de cada decisión.

La decisión seleccionada, dentro de todas las posibles variantes, que ofrezca la mejor solución en relación con el objetivo propuesto, se denomina *óptima*.

1.1 Definiciones básicas

Funciones de decisión. ~~Sea la tarea de estimación de procesos aleatorios, en la cual se tiene la trayectoria de un vector aleatorio $\mathbf{y}(t) \in Y$. Asimismo, sea $\mathbf{x}(t) \in X$ un proceso aleatorio vectorial, cuyas trayectorias no son conocidas por el observador y que corresponden al valor verdadero del proceso, pero cuya información está contenida en los resultados de observación $\mathbf{y}(t)$.~~

Sea el vector $\mathbf{D} \in D$ de cada posible solución que se puede tomar con respecto a $\mathbf{x}(t)$ a partir de los resultados de observación $\mathbf{y}(t)$, es decir, cada solución establece una relación entre los puntos de $\mathbf{y}$. Sea $\mathbf{g} \in G$ la transformación de la forma $\mathbf{D} = \mathbf{g}(\mathbf{y})$.

Las funciones de decisión pueden ser tanto **determinísticas**, cuando la transformación no contiene ninguna medida de incertidumbre, **como randomizadas**, cuando la transformación implica que, para cada $\mathbf{y}$, cualquier $\mathbf{D}$ se toma con una medida de probabilidad condicional $p(\mathbf{D} | \mathbf{y})$.

Funciones de pérdida. Como resultado de la toma de una u otra decisión, pueden ocurrir errores, por lo cual se establece una medida cuantitativa de la respectiva ganancia o pérdida, en forma de dependencia $f_c\{\mathbf{x}, \mathbf{d}\}$ denominada *función de pérdida*, que se selecciona en concordancia con la naturaleza física de la tarea a resolver. Debido a que la solución $\mathbf{D} = \mathbf{g}(\mathbf{y})$ depende de la trayectoria del proceso aleatorio $\mathbf{y}(t)$, entonces el valor actual de pérdida $f_c\{\mathbf{x}, \mathbf{g}(\mathbf{y})\}$ es también aleatorio. Por lo tanto, las funciones de decisión deben seleccionarse de acuerdo con la comparación de las características de aleatoriedad de la función de pérdida.

Así, por ejemplo, para el caso de la tarea de estimación, la decisión $\mathbf{D}$ representa la estimación $\tilde{\mathbf{x}}(t)$ que corresponde al vector proceso aleatorio $\mathbf{x}(t)$. Al introducir la medida de error $\boldsymbol{\varepsilon}(t) = \mathbf{x}(t) - \tilde{\mathbf{x}}(t)$, la función de pérdida se describe como $f_c\{\mathbf{x}, \tilde{\mathbf{x}}\} \triangleq f_c\{\boldsymbol{\varepsilon}\}$. A la función de pérdidas se denomina *permitida* si presenta las siguientes propiedades:

- (a) $f_c\{\boldsymbol{\varepsilon}\}$ es una función escalar de n variables, correspondientes a la dimensión del proceso $\mathbf{x}(t)$.
- (b) $f_c\{\boldsymbol{\varepsilon} = 0\} = 0$.
- (c) $f_c\{\boldsymbol{\varepsilon}\} = f_c\{-\boldsymbol{\varepsilon}\}$, es decir, la función de pérdida es simétrica, en el sentido de que no importa en qué dirección se tenga el error, la pérdida se considera la misma.
- (d) $f_c\{\boldsymbol{\varepsilon}_m\} > f_c\{\boldsymbol{\varepsilon}_n\}, \forall \rho(\boldsymbol{\varepsilon}_m) \geq \rho(\boldsymbol{\varepsilon}_n)$, donde $\boldsymbol{\varepsilon}_m$ y $\boldsymbol{\varepsilon}_n$ son los valores de error de estimación, ρ es una función escalar positiva semidefinida convexa, con argumento de n variables, y corresponde a la medida de distancia del error $\boldsymbol{\varepsilon}$ desde el origen de las coordenadas de un espacio euclidiano de dimensión n . La función $f_c\{\boldsymbol{\varepsilon}\}$ es monótona ascendente con respecto al incremento del argumento $\boldsymbol{\varepsilon}$.

Figure 1: Funciones de pérdida.

En la práctica, se hace un amplio uso de las siguientes tres formas de funciones permitidas de pérdida:

$$a. \text{ Cuadrática, Figura 1(a), } f_c(\boldsymbol{\varepsilon}) = \|\boldsymbol{\varepsilon}\|_{\mathbf{B}}^2 \quad (1a)$$

$$b. \text{ Por módulo, Figura 1(b), } f_c(\boldsymbol{\varepsilon}) = \|\boldsymbol{\varepsilon}\|_{\mathbf{B}} \quad (1b)$$

$$c. \text{ Simple, Figura 1(c), } f_c(\boldsymbol{\varepsilon}) = \begin{cases} 0, & \|\boldsymbol{\varepsilon}\|_{\mathbf{B}} < e/2 \\ 1/e, & \|\boldsymbol{\varepsilon}\|_{\mathbf{B}} \geq e/2 \end{cases} \quad (1c)$$

donde $\|\cdot\|$ es la norma del vector, ε es una constante, y $\mathbf{B}$ es una matriz positiva semidefinida de dimensión $n \times n$, compuesta por los elementos b_{ij} que son factores de peso. En la estimación de señales, es habitual el empleo de la norma del error:

$$\|\varepsilon_{\mathbf{B}}^2\| = \varepsilon^T \mathbf{B} \varepsilon$$

Funciones de riesgo. Como se indicó anteriormente, los valores concretos de la función de pérdida $f_c(\mathbf{x}, \mathbf{D})$ son aleatorios. Por lo tanto, las funciones de decisión deben seleccionarse con base en la comparación de las propiedades estadísticas de dicha función de pérdida. Esta comparación se realiza a través de la función de riesgo (o simplemente riesgo), que representa la pérdida esperada promedio sobre el conjunto de decisiones posibles.

La selección de la decisión óptima se lleva a cabo mediante la minimización del riesgo sobre todas las posibles funciones de decisión. En la teoría de decisiones, se emplea como criterio generalizado de calidad el riesgo medio, que para el caso de funciones de decisión *randomizadas* se define como la esperanza matemática de la función de pérdida:

$$R = E\{f_c(\mathbf{x}, \mathbf{D})\} = \iiint f_c(\mathbf{x}, \mathbf{D}) p(\mathbf{D} | \mathbf{y}) p(\mathbf{x}, \mathbf{y}) d\mathbf{D} d\mathbf{y} d\mathbf{x} \quad (2)$$

donde $p(\mathbf{D} | \mathbf{y})$ es la densidad de probabilidad condicional asociada a la decisión $\mathbf{D}$ para un valor dado del vector de observación $\mathbf{y}$ (caracteriza la función de decisión), y $p(\mathbf{x}, \mathbf{y})$ es la función de densidad de probabilidad (FDP) conjunta de los vectores $\mathbf{x}$ y $\mathbf{y}$.

Dado que se cumple:

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x})p(\mathbf{y} | \mathbf{x}) = p(\mathbf{y})p(\mathbf{x} | \mathbf{y})$$

la expresión del riesgo medio (2) puede representarse de forma equivalente como:

$$R = \iiint f_c(\mathbf{x}, \mathbf{D}) p(\mathbf{D} | \mathbf{y}) p(\mathbf{x} | \mathbf{y}) p(\mathbf{y}) d\mathbf{D} d\mathbf{y} d\mathbf{x} \quad (3a)$$

$$R = \iiint f_c(\mathbf{x}, \mathbf{D}) p(\mathbf{D} | \mathbf{y}) p(\mathbf{y} | \mathbf{x}) p(\mathbf{x}) d\mathbf{D} d\mathbf{y} d\mathbf{x} \quad (3b)$$

donde $p(\mathbf{x} | \mathbf{y})$ es la FDP condicional del proceso no observado $\mathbf{x}(t)$ dado $\mathbf{y}(t)$, $p(\mathbf{x})$ y $p(\mathbf{y})$ son las FDP marginales de $\mathbf{x}$ y $\mathbf{y}$, respectivamente, y $p(\mathbf{y} | \mathbf{x})$ representa la función de verosimilitud del proceso observado.

Las ecuaciones (2), (3a) y (3b) caracterizan la pérdida esperada en promedio para todas las posibles decisiones $\mathbf{D} \in D$ y todos los valores posibles de $\mathbf{x}$ y $\mathbf{y}$. La optimización de la función de decisión consiste en seleccionar aquella función $p(\mathbf{D} | \mathbf{y})$ que minimice el riesgo medio definido en (2).

En el caso de funciones de decisión *no randomizadas*, a cada valor $\mathbf{y}$ le corresponde una única solución $\mathbf{D} = \mathbf{g}(\mathbf{y})$, y la FDP condicional es una delta de Dirac: $p(\mathbf{D} | \mathbf{y}) = \delta(\mathbf{D} - \mathbf{g}(\mathbf{y}))$. En este caso, el riesgo medio se reduce a:

$$R_g = E \{f_c(\mathbf{x}, \mathbf{g}(\mathbf{y}))\} = \iint f_c(\mathbf{x}, \mathbf{g}(\mathbf{y})) p(\mathbf{x}, \mathbf{y}) d\mathbf{y} d\mathbf{x} \quad (4)$$

En general, el riesgo medio (4) es una función no lineal con respecto a la función de decisión $\mathbf{g}(\mathbf{y})$. Las formas equivalentes del riesgo medio para funciones de decisión no randomizadas son:

$$R_g = \iint f_c(\mathbf{x}, \mathbf{g}(\mathbf{y})) p(\mathbf{x} | \mathbf{y}) p(\mathbf{y}) d\mathbf{y} d\mathbf{x} \quad (5a)$$

$$R_g = \iint f_c(\mathbf{x}, \mathbf{g}(\mathbf{y})) p(\mathbf{y} | \mathbf{x}) p(\mathbf{x}) d\mathbf{y} d\mathbf{x} \quad (5b)$$

A partir de estas, se puede definir el riesgo condicional $r_g(\mathbf{x})$, correspondiente a la pérdida promedio ponderada por la función de verosimilitud $p(\mathbf{y} | \mathbf{x})$ para un valor dado de $\mathbf{x}$:

$$r_g(\mathbf{x}) = \int f_c(\mathbf{x}, \mathbf{g}(\mathbf{y})) p(\mathbf{y} | \mathbf{x}) d\mathbf{y} \quad (6)$$

El promedio del riesgo condicional $r_g(\mathbf{x})$ sobre todos los posibles valores de $\mathbf{x}$, conforme a la expresión (5b), da lugar al riesgo medio:

$$R_g = \int r_g(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \quad (7)$$

El riesgo condicional $r_g(\mathbf{x})$ caracteriza la calidad del sistema basado en la función de decisión $\mathbf{g}(\mathbf{y})$ para un valor dado de $\mathbf{x}$. Por tanto, se prefiere aquella función de decisión $\mathbf{g}(\mathbf{y})$ que minimice $r_g(\mathbf{x})$.

Se dice que una función de decisión $\mathbf{g}_1(\mathbf{y})$ es *uniformemente mejor* que otra función $\mathbf{g}_2(\mathbf{y})$ si se cumple que $r_{g1}(\mathbf{x}) \leq r_{g2}(\mathbf{x})$ para todo $\mathbf{x} \in X$, y estrictamente menor para al menos un valor de $\mathbf{x}$ [?].

Una función de decisión $\mathbf{g}$ se denomina *permitida* si no existe otra función de decisión $\mathbf{g}_1$ que sea uniformemente mejor que $\mathbf{g}$ dentro del conjunto G de funciones consideradas.

Asimismo, se dice que la clase G de funciones de decisión es *completa* si para toda función $\mathbf{g}_i \notin G$ existe una función $\mathbf{g} \in G$ que es uniformemente mejor que $\mathbf{g}_i$. En consecuencia, si se cuenta con una clase completa G , la búsqueda de funciones óptimas puede limitarse a dicho conjunto, sin necesidad de explorar decisiones fuera de él. Por ello, la construcción de clases completas resulta esencial en la teoría de decisión estadística.

Cuando se dispone de una **función de decisión $\mathbf{g}(\mathbf{y})$ que minimiza el riesgo condicional $r_g(\mathbf{x})$ de manera suficientemente diferenciada para distintos valores de $\mathbf{x}$, la elección de una decisión óptima se realiza empleando criterios diversos, tales como Bayes, minimax, o máxima verosimilitud, entre otros.**

En situaciones donde las observaciones corresponden a conjuntos de valores aleatorios o a procesos continuos en el tiempo con dimensión alta o infinita, se recurre al concepto de *estadísticas suficientes*. Este concepto define una

transformación $\gamma(\mathbf{y})$ que preserva toda la información relevante para la toma de decisiones contenida en las observaciones $\mathbf{y} \in Y$. Para estas transformaciones, la función de decisión óptima $\mathbf{g}(\gamma(\mathbf{y}))$ proporciona el mismo valor de riesgo que la función óptima $\mathbf{g}(\mathbf{y})$. Por tanto, las estadísticas suficientes son herramientas fundamentales para determinar funciones de decisión óptimas, tanto en enfoques bayesianos como no bayesianos.

En el caso de la aproximación bayesiana para la toma de decisiones, las estadísticas suficientes corresponden a funciones vectoriales conocidas $\boldsymbol{\gamma} = \{\gamma_i(\mathbf{y}) : i = 1, \dots, n\}$, mediante las cuales la función de densidad de probabilidad (FDP) conjunta se puede expresar como:

$$p(\mathbf{x}, \mathbf{y}) = f_c(\mathbf{y}) f(\gamma_1(\mathbf{y}), \dots, \gamma_n(\mathbf{y}), \mathbf{x})$$

donde el factor $f_c(\mathbf{y})$ no depende de $\mathbf{x}$, y la función f está relacionada con $\mathbf{y}$ únicamente a través de las funciones $\gamma_1(\mathbf{y}), \dots, \gamma_n(\mathbf{y})$.

Como puede observarse, en este caso f depende solo de una cantidad finita de variables. Además, la FDP a posteriori depende exclusivamente de las estadísticas suficientes $\gamma_i(\mathbf{y})$:

$$p(\mathbf{x} | \mathbf{y}) = \frac{f(\gamma_1(\mathbf{y}), \dots, \gamma_n(\mathbf{y}), \mathbf{x})}{\int f(\gamma_1(\mathbf{y}), \dots, \gamma_n(\mathbf{y}), \mathbf{x}) d\mathbf{x}}$$

Por lo tanto, las funciones $\gamma_i(\mathbf{y})$ son suficientes para el cálculo de la FDP condicional a posteriori. Es decir,

$$p(\mathbf{x} | \mathbf{y}) = p(\mathbf{x} | \gamma_1(\mathbf{y}), \dots, \gamma_n(\mathbf{y}))$$

Al sustituir esta expresión en la ecuación (5a), se concluye que el algoritmo óptimo de estimación también depende de $\mathbf{y}$ únicamente a través de la estadística suficiente. Por consiguiente,

$$\mathbf{g}(\mathbf{y}) = \mathbf{g}(\gamma_1(\mathbf{y}), \dots, \gamma_n(\mathbf{y}))$$

lo cual confirma que toda la información relevante para la decisión está contenida en las **estadísticas suficientes**.

En la aproximación no bayesiana para la toma de decisiones mediante el uso de estadísticas suficientes, de manera similar, la función de verosimilitud adopta la forma $p(\mathbf{y} | \mathbf{x}) = f_c(\mathbf{y})$.

Una estadística suficiente se considera más valiosa cuanto mayor comprensión proporciona de los datos observados $\mathbf{y}(t)$, es decir, cuanto menor sea su dimensión de representación. La transformación suficiente de mínima dimensión se denomina *estadística mínima suficiente* para una clase dada de tareas. Entre los ejemplos típicos de estadísticas mínimas suficientes se encuentran la relación de verosimilitud en la tarea de detección binaria de señales y el funcional de verosimilitud en la estimación de parámetros de señales.

La tarea fundamental de estimación corresponde al análisis del riesgo condicional dado $\mathbf{y}$, conocido como riesgo a posteriori $r_g(\mathbf{y})$, el cual es la esperanza matemática condicional de la función de pérdida para una función de decisión

dada $\mathbf{g}$. El riesgo a posteriori $r_g(\mathbf{y})$ se calcula como el promedio de la función de pérdida sobre toda la función de densidad de probabilidad a posteriori, para una trayectoria fija $\mathbf{y}$:

$$r_g(\mathbf{y}) = \int f_c(\mathbf{x}, \mathbf{g}(\mathbf{y})) p(\mathbf{x} | \mathbf{y}) d\mathbf{x} \quad (8)$$

El riesgo definido en (8) representa el valor esperado de las pérdidas asociado a la toma de la decisión $\mathbf{D} = \mathbf{g}(\mathbf{y}) \in D$, correspondiente a una observación dada $\mathbf{y}$. A su vez, el riesgo medio R_g , en concordancia con la expresión (5a), se obtiene como el promedio del riesgo a posteriori $r_g(\mathbf{y})$ ponderado por la densidad de probabilidad de $\mathbf{y}$:

$$R_g = \int r_g(\mathbf{y}) p(\mathbf{y}) d\mathbf{y} \quad (9)$$

1.2 Decisión Bayesiana

En general, la búsqueda de la función de decisión óptima considera dos casos extremos de análisis sobre el estado de conocimiento a priori de un proceso vectorial no observado $\mathbf{x}$: (i) conocimiento completo a priori, cuando se dispone de la función de densidad de probabilidad (FDP) $p(\mathbf{x})$, y (ii) conocimiento incompleto a priori, cuando $p(\mathbf{x})$ es totalmente desconocida. En el primer caso, se construyen las *funciones de decisión bayesiana*, y en el segundo, las denominadas *funciones de decisión no bayesiana*.

En la aproximación bayesiana se cumplen las siguientes condiciones:

1. El proceso $\mathbf{x}$ es aleatorio y existe una función de densidad marginal $p(\mathbf{x})$.
2. La función de densidad a priori $p(\mathbf{x})$ es conocida por el observador.

En este contexto, la decisión óptima se determina minimizando el riesgo medio definido en (4):

$$\hat{R}_g = \min_{\mathbf{g}} R_g = \min_{\mathbf{g}} \int \int f_c(\mathbf{x}, \mathbf{g}(\mathbf{y})) p(\mathbf{x}, \mathbf{y}) d\mathbf{x} d\mathbf{y} \quad (10)$$

La función $\hat{\mathbf{g}}$ que satisface (10) se denomina *función de decisión bayesiana*, al igual que la decisión y el riesgo medio correspondientes. Así, el criterio bayesiano de optimización consiste en la minimización del riesgo medio para una FDP a priori $p(\mathbf{x})$ dada.

Cabe resaltar que el riesgo medio varía en función de la estructura de la función de pérdida $f_c(\mathbf{x}, \mathbf{g}(\mathbf{y}))$, por lo que el criterio de optimización, en general, depende de la forma específica de esta función. No obstante, se sabe que el conjunto total de decisiones bayesianas, respecto a todas las posibles funciones a priori $p(\mathbf{x})$, forma una clase completa.

Como se deduce de (9), el procedimiento de minimización del riesgo medio R_g mediante la elección de $\mathbf{g}$ implica, a su vez, la minimización del riesgo a posteriori $r_g(\mathbf{y})$, definido en (8), ponderado por la FDP $p(\mathbf{y})$. Esto significa que

el criterio de optimización bayesiano es equivalente al criterio de minimización del riesgo a posteriori:

$$\hat{r}_g(\mathbf{y}) = \min_{\mathbf{g}} r_g(\mathbf{y}) = \min_{\mathbf{g}} \int f_c(\mathbf{x}, \mathbf{g}(\mathbf{y})) p(\mathbf{x} | \mathbf{y}) d\mathbf{x} \quad (11)$$

Desde el punto de vista analítico, la tarea de minimización expresada en (11) puede admitir solución en ciertos casos particulares.

En la estimación de procesos aleatorios $\mathbf{x}$, la función de pérdida generalmente se determina a partir de un error $\boldsymbol{\varepsilon}$, cuyo valor puede ser minimizado seleccionando la estimación $\tilde{\mathbf{x}}$. La estimación que cumple con esta condición se denomina *óptima bayesiana*, o simplemente *óptima* cuando se asume tácitamente que es bayesiana. En general, esta estimación depende de la elección de la función de pérdida $f_c(\boldsymbol{\varepsilon})$. Sin embargo, para una amplia clase de tareas, las estimaciones que son óptimas para una clase de funciones de pérdida mantienen esta propiedad para la clase completa de funciones de pérdida. Esto implica que se puede hablar de la invariabilidad de la estimación óptima.

En particular, según el teorema de Sherman [?], si $f_c(\boldsymbol{\varepsilon})$ es una función permitida de pérdida y la función de densidad de probabilidad (FDP) a posteriori del proceso $\mathbf{x}$ es unimodal y simétrica respecto a la moda, entonces la estimación óptima bayesiana corresponde a la *esperanza matemática condicional* del vector $\mathbf{x}$. Este caso se presenta, por ejemplo, en la estimación lineal de procesos gaussianos.

Sea la función cuadrática de pérdida (1a) y el riesgo bayesiano (10). Hallar el valor de la estimación $\tilde{\mathbf{x}}$ que minimice el error para una observación dada $\mathbf{y}$.

El riesgo medio bayesiano para el criterio de error dado tiene la forma:

$$R_g = \iint (\mathbf{x} - \tilde{\mathbf{x}})^T \mathbf{B} (\mathbf{x} - \tilde{\mathbf{x}}) p(\mathbf{x}, \mathbf{y}) d\mathbf{x} d\mathbf{y}$$

Por lo tanto, el riesgo a posteriori tiene la forma:

$$r_g(\mathbf{y}) = \int (\mathbf{x} - \tilde{\mathbf{x}})^T \mathbf{B} (\mathbf{x} - \tilde{\mathbf{x}}) p(\mathbf{x} | \mathbf{y}) d\mathbf{x} \quad (12)$$

donde $\mathbf{B}$ es una matriz positiva definida, cuyos elementos tienen las unidades de la función de penalización por error sobre las unidades del producto de los errores de las respectivas componentes del proceso vectorial estimado $\mathbf{x}$. Como se observa en (12), el riesgo a posteriori está relacionado con el momento central de segundo orden de la FDP a posteriori, lo que significa que el mínimo valor de posible riesgo a posteriori, en el caso de la función cuadrática de pérdida, se alcanza con la estimación $\tilde{\mathbf{x}}$ que minimiza la traza de la matriz de momentos centrales escalares de segundo orden (si el proceso es escalar, esto se traduce en el valor mínimo del error cuadrático medio).

En este caso, el valor de la estimación que minimiza el error cuadrático medio, dada la observación $\mathbf{y}$, se obtiene igualando a cero el gradiente de $r_g(\mathbf{y})$ respecto a $\tilde{\mathbf{x}}$:

$$\frac{\partial r_g(\mathbf{y})}{\partial \tilde{\mathbf{x}}} = 2 \int \mathbf{B}(\tilde{\mathbf{y}} - \mathbf{x}) p(\mathbf{x} | \mathbf{y}) d\mathbf{x} = 0 \quad (13)$$

La igualdad (13) se cumple cuando:

$$\tilde{\mathbf{x}} \int p(\mathbf{x} | \mathbf{y}) d\mathbf{x} = \int \mathbf{x} p(\mathbf{x} | \mathbf{y}) d\mathbf{x}$$

Asumiendo que se cumple la condición de normalización para $p(\mathbf{x} | \mathbf{y})$, se obtiene:

$$\tilde{\mathbf{x}} = \int \mathbf{x} p(\mathbf{x} | \mathbf{y}) d\mathbf{x} \quad (14)$$

Por lo tanto, la estimación con el mínimo error cuadrático medio corresponde al valor de la FDP a posteriori $p(\mathbf{x} | \mathbf{y})$. De (14), se observa que la estimación óptima no depende de la matriz $\mathbf{B}$, lo que implica que se tiene un óptimo general para todas las componentes del proceso $\mathbf{x}$.

En el ejemplo anterior, supóngase que se tiene la función simple de pérdida definida en (1c).

En este caso, la minimización del riesgo a posteriori de (11), que toma la forma

$$r_g(\mathbf{y}) = \frac{1}{\varepsilon} \int_{E_1} p(\mathbf{x} | \mathbf{y}) d\mathbf{x}$$

corresponde a la selección del valor $\tilde{\mathbf{x}}$, que maximiza la expresión

$$\frac{1}{\varepsilon} - r_g(\mathbf{y}) = \frac{1}{\varepsilon} - \frac{1}{\varepsilon} \int_{E_1} p(\mathbf{x} | \mathbf{y}) d\mathbf{x} = \frac{1}{\varepsilon} \int_{E_0} p(\mathbf{x} | \mathbf{y}) d\mathbf{x}$$

donde la integración se realiza sobre el espacio E_1 , en el cual $\|\varepsilon\|_{\mathbf{B}} \geq \frac{\varepsilon}{2}$, o sobre el espacio E_0 , donde se cumple $\|\varepsilon\|_{\mathbf{B}} < \frac{\varepsilon}{2}$. El uso de la función simple de pérdidas implica un valor relativamente pequeño para el intervalo ε ($\varepsilon \rightarrow 0$).

Entonces, para obtener el máximo de la última expresión como el valor de la estimación óptima $\tilde{\mathbf{x}}$, en cada trayectoria $\mathbf{y}$ dada, se debe seleccionar el valor de $\mathbf{x}$ para el cual $p(\mathbf{x} | \mathbf{y})$ toma el máximo valor posible. Es decir, la estimación $\tilde{\mathbf{x}}$ corresponde a la moda de $p(\mathbf{x} | \mathbf{y})$. Esta estimación se denomina *estimación por máximo de densidad de probabilidad a posteriori*.

Conocida la trayectoria $\mathbf{y}$, la estimación óptima $\tilde{\mathbf{x}}$ se obtiene como la raíz de la siguiente ecuación:

$$\left. \frac{\partial p(\mathbf{x} | \mathbf{y})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\tilde{\mathbf{x}}} = 0 \quad (15)$$

El valor de la estimación óptima $\tilde{\mathbf{x}}$ se puede obtener mediante la maximización de la función $p(\mathbf{x} | \mathbf{y})$ con respecto a $\mathbf{x}$. Basado en el teorema de Bayes, (??), se tiene la relación condicional $p(\mathbf{x} | \mathbf{y}) = p(\mathbf{x} | \mathbf{y})p(\mathbf{x})|p(\mathbf{y})$, es decir,

$$\ln p(\mathbf{x} | \mathbf{y}) = \ln p(\mathbf{x}, \mathbf{y}) - \ln p(\mathbf{y}) = \ln p(\mathbf{x} | \mathbf{y}) + \ln p(\mathbf{x}) - \ln p(\mathbf{y}).$$

Dado que $p(\mathbf{y})$ no depende de la variable $\mathbf{x}$, la maximización de $p(\mathbf{x} | \mathbf{y})$ se reduce a hallar el valor máximo de la densidad de probabilidad conjunta $p(\mathbf{x}, \mathbf{y})$. De esta manera, el valor óptimo de la estimación se puede hallar como la raíz de una de las siguientes ecuaciones:

$$\left. \frac{\partial p(\mathbf{x}, \mathbf{y})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\tilde{\mathbf{x}}} = \left. \frac{\partial p(\mathbf{y} | \mathbf{x})p(\mathbf{x})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\tilde{\mathbf{x}}} = 0 \quad (15a)$$

$$\left. \frac{\partial \ln p(\mathbf{x}, \mathbf{y})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\tilde{\mathbf{x}}} = \left(\left. \frac{\partial \ln p(\mathbf{y} | \mathbf{x})}{\partial \mathbf{x}} + \frac{\partial \ln p(\mathbf{x})}{\partial \mathbf{x}} \right) \right|_{\mathbf{x}=\tilde{\mathbf{x}}} = 0 \quad (15b)$$

La solución de la función de pérdida, en tareas de aplicación concretas, en parte se realiza siguiendo el principio de implementación simple de los algoritmos óptimos de estimación. Desde este punto de vista, como se observa en (14) y (15), la estimación óptima, en el caso de la función simple de pérdida, se determina por las propiedades locales de la FDP a posteriori de las componentes de estimación del vector $\mathbf{x}$, cerca de su máximo global. En cambio, cuando se tiene la función cuadrática de pérdida, la estimación se determina por la forma de cambio de la FDP a priori, pero en todo el intervalo del vector $\mathbf{x}$.

Por esta razón, es de esperar que para algunas tareas de estimación sea preferible la realización del algoritmo (15), que requiere un menor detalle en la descripción de la FDP a posteriori, en comparación con el algoritmo (14), aunque es posible que su rendimiento sea inferior.

1.3 Decisión no Bayesiana

La aproximación bayesiana implica que, sobre el proceso $\mathbf{x}$, siendo aleatorio, se conoce su medida probabilística, en particular, su función de densidad de probabilidad (FDP). En caso contrario, se emplean diferentes métodos no bayesianos para seleccionar la mejor función de decisión.

Método de máxima verosimilitud. Se considera que las mejores estimaciones bayesianas se obtienen mediante el método del máximo de probabilidad a posteriori, cuando la estimación se calcula mediante la maximización de la FDP conjunta $p(\mathbf{x}, \mathbf{y}) = p(\mathbf{y} | \mathbf{x})p(\mathbf{x})$. Sin embargo, en la práctica, es común no tener información a priori sobre el proceso $\mathbf{x}$, lo cual hace imposible resolver las ecuaciones (15a) y (15b) del ejemplo 1.2. Por lo tanto, una forma aproximada de obtener la estimación óptima $\tilde{\mathbf{x}}$ es simplificando el sistema de ecuaciones, manteniendo únicamente la función de verosimilitud. En este caso, la estimación obtenida se denomina *máxima verosimilitud* y se determina mediante la solución de una de las siguientes ecuaciones:

$$\left. \frac{\partial p(\mathbf{y} | \mathbf{x})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\tilde{\mathbf{x}}} = 0 \quad (16a)$$

$$\left. \frac{\partial \ln p(\mathbf{y} | \mathbf{x})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\tilde{\mathbf{x}}} = 0 \quad (16b)$$

El método de máxima verosimilitud puede considerarse un caso particular de la estimación bayesiana. Por ejemplo, si en alguna de las expresiones (16a) o (16b) se asume que el proceso aleatorio $\mathbf{x}$ tiene una FDP gaussiana y para un aumento ilimitado de las varianzas de todas las componentes del vector $\mathbf{x}$, se cumple que:

$$\frac{\partial \ln p(\mathbf{x})}{\partial \mathbf{x}} = 0,$$

entonces la expresión (15b) se transforma en (16b). Además, al mismo resultado se llega asumiendo que la FDP es uniforme.

En general, el cambio de (15a) a (16a), o de (15b) a (16b), es aceptable y está condicionado al hecho de que la observación $\mathbf{y}$ contenga tanta información sobre el verdadero valor de $\mathbf{x}$, que su estimación $\tilde{\mathbf{x}}$ tenga una menor dispersión con respecto al valor verdadero $\mathbf{x}$. Esta dispersión debe ser menor que la dispersión determinada a priori por la densidad $p(\mathbf{x})$. Además, se debe asegurar que $p(\mathbf{x})$ no contenga picos muy altos en las regiones de definición de $\mathbf{x}$. En algunos casos, cuando la información a priori sobre la FDP es insuficiente, se asumen aproximaciones gaussianas o uniformes, obteniendo estimaciones denominadas *seudobayesianas* [?].

El error cuadrático medio de estimación para el método de máxima verosimilitud es mayor que para el caso de estimación seudobayesiana y, por supuesto, mucho mayor que para el caso bayesiano. La razón de este comportamiento del error de estimación radica en que la construcción del estimador bayesiano incluye la información a priori del vector estimado $\mathbf{x}$, mientras que en el caso de máxima verosimilitud, esta se ignora o se asume igual para el peor caso.

Método minimax. De la expresión (7), se observa que a cada vector $\mathbf{x}$ le corresponde un valor de riesgo condicional $r_g(\mathbf{x})$, lo que significa que este valor cambia para cada una de las señales, y por lo tanto, existirá un valor máximo $r_g(\mathbf{x})_{\max}$ para todos los posibles valores de $\mathbf{x}$.

La función de decisión $\hat{g}(\mathbf{y})$ determina la solución minimax si se cumple que:

$$\sup \hat{r}_g(\mathbf{x}) \leq \sup r_g(\mathbf{x}).$$

Asumiendo la existencia de los valores extremos, la anterior relación toma la forma:

$$\min_g \max_{\mathbf{x}} r_g(\mathbf{x}) = \max_{\mathbf{x}} \hat{r}_g(\mathbf{x}). \quad (17)$$

El método de estimación minimax, descrito por (17), implica la minimización, por todo g , del riesgo condicional $r_g(\mathbf{x})$ para el peor de los casos, es decir, para todos los valores de $\mathbf{x}$. Además, la función de decisión $\hat{g}(\mathbf{x})$ minimiza, por todos los valores de $\mathbf{x}$, el máximo valor de la función de riesgo condicional $r_g(\mathbf{x})$. La principal particularidad del método (17) es que garantiza un cierto valor de éxito, referido al peor de los casos a ser considerado. Sin embargo, la estimación

puede resultar demasiado lejana de las situaciones con mayor probabilidad de ocurrir.

La solución minimax, en muchas tareas de aplicación real, implica un procedimiento bastante complejo de resolver. Sin embargo, si se asocia el método minimax con el bayesiano, la complejidad de la solución disminuye. Así, por ejemplo, la función de decisión minimax $\hat{g}(x)$, dadas ciertas restricciones de carácter muy suave (que son simples de cumplir), corresponde a la función bayesiana con respecto a la distribución a priori menos favorable, que a menudo resulta ser la FDP uniforme.

Sea $x(t)$ un proceso aleatorio escalar, cuyos valores deben localizarse dentro del intervalo de trabajo $-a < x < a$, $x \in R$. En caso contrario, el sistema se considera desintonizado y debe generarse una señal de alarma, por lo menos, mientras el proceso no regrese al intervalo indicado de trabajo. Hallar la estimación óptima $\tilde{x}(t)$, dada la trayectoria de observación $y(t)$ con valores pertenecientes al intervalo (t_0, t) , que corresponde a una función conocida del proceso estimado más una perturbación.

La respectiva decisión $d = g(y)$ es el resultado de la filtración, es decir, $g(y) = \tilde{x}(t)$, que se determina por alguna de las funciones de pérdida, por ejemplo, la forma simple (1c):

$$f_c(e) = \begin{cases} 0, & |e| \leq \mu \\ c, & |e| > \mu \end{cases}$$

donde $e(t) = x(t) - \tilde{x}(t)$, $c = \text{const.}$ y $\mu = \text{const.}$

El sistema puede generar error en dos situaciones: una, cuando la estimación está dentro del intervalo permitido, mientras que el valor verdadero no lo está (error de primer tipo), o cuando la estimación está fuera del intervalo, pero el valor verdadero aún se conserva en el intervalo de sintonización (error de segundo tipo). En el primer caso, la función de pérdidas se asume igual a $A = \text{const.}$, y para el segundo caso, $B = \text{const.}$